

Построение и исследование моделей Word2Vec для белорусского языка

Роман Кравец

Данные

- 80 произведений с сайта knihi.com # requests, beautifulsoup4
- Период: 40е–80е гг. XX века
- Сегментация на предложения, токенизация, # stanza
лемматизация, определение части речи слов
- Удалены предложения с латинскими символами, «и», «щ», «ъ»
- Итоговый объём: 431 333 предложения, 4 242 840 токенов

Калі б у мяне спыталі, якая рыса гэтага чалавека перш за ўсё кідаецца ў вочы, я б сказаў: «Старамодная галантнасць».

["калі", "б", "у", "я", "спытаць", "які", "рыса", "гэты", "чалавек", "перш", "за", "усё", "кідацца", "у", "вока", "я", "б", "сказаць", "старамодны", "галантнасць"]

Модели

Обучены три модели с длиной вектора 100: # gensim

- алгоритм – skip-gram, размер контекстного окна – 5
- алгоритм – skip-gram, размер контекстного окна – 10
- алгоритм – CBOW, размер контекстного окна – 5

Количество векторов: 114 491

Предобученная модель

На сайте FastText имеются предобученные модели для 157 языков, в том числе и белорусского

- Данные для обучения: Wikipedia, Common Crawl
- Алгоритм: CBOW
- Размер контекстного окна: 5
- Длина векторов: 300

Количество векторов: 1 714 011

Оценка качества моделей

- Датасет «8-8-8»
- Датасет состоит из 8 тем: цвета, животные, месяцы, части тела, праздники, город, транспорт, кухня
- Для каждой темы: 8 связанных между собой слов и 8 слов, имеющих к теме слабое отношение
- Задача: поиск лишнего слова в наборе из восьми слов первого списка и одного слова второго списка
- Оценка точности: процент правильно угаданных «лишних» слов.

Оценка качества моделей: цвета

[чырвоны, белы, сіні, блакітны, зялёны, чорны, жоўты, карычневый]

[красный, белый, синий, голубой, зелёный, чёрный, жёлтый, коричневый]

[мастак, вясёлка, гарбата, аловак, неба, плот, эмоцыя, старажытнасць]

[художник, радуга, чай, карандаш, небо, забор, эмоция, древность]

	↕ skipgram w5	↕ skipgram w10	↕ cbow w5	↕ pretrained
мастак	+	+	+	+
вясёлка	- белы	- чырвоны	+	+
гарбата	+	- чырвоны	+	+
аловак	+	+	+	+
неба	+	+	+	+
плот	+	+	+	+
эмоцыя	+	+	+	+
старажытнасць	+	+	+	+
Correct predictions	7/8	6/8	8/8	8/8

Оценка качества моделей: місяці

[студзень, сакавік, май, ліпень, жнівень, верасень, лістапад, снежань]

[январь, март, май, июль, август, сентябрь, ноябрь, декабрь]

[серада, зіма, дата, год, астралогія, нараджэнне, мяч, папера]

[среда, зима, дата, год, астрология, рождение, мяч, бумага]

	↕ skipgram w5	↕ skipgram w10	↕ cbow w5	↕ pretrained
серада	+	+	+	+
зіма	+	+	+	+
дата	+	+	+	+
год	+	+	+	+
астралогія	+	+	+	+
нараджэнне	+	+	+	+
мяч	+	+	+	+
папера	+	+	+	+
Correct predictions	8/8	8/8	8/8	8/8

Оценка качества моделей: транспорт

[аўтобус, тралейбус, машына, трамвай, метро, ровар, самакат, матацыкл]

[автобус, троллейбус, машина, трамвай, метро, велосипед, самокат, мотоцикл]

[дарога, кола, горад, квіток, маршрут, хуткасць, груша, месяц]

[дорога, колесо, город, талон/квитанция, маршрут, скорость, груша, месяц/луна]

	↕ skipgram w5	↕ skipgram w10	↕ cbow w5	↕ pretrained
дарога	+	+	- самакат	+
кола	+	+	- самакат	+
горад	+	+	- самакат	+
квіток	- машына	+	- самакат	- метро
маршрут	- машына	+	- самакат	- метро
хуткасць	+	+	- самакат	+
груша	+	+	- самакат	+
месяц	+	+	- самакат	+
Correct predictions	6/8	8/8	0/8	6/8

Оценка качества моделей: кухня

[рондаль, патэлья, чайнік, духоўка, пліта, тарка, халадзільнік, скавародка]

[кастрыля с ручкой, сковородка, чайник, духовка, плита, тёрка, холодильник, сковородка]

[страва, кухар, пакой, вада, кватэра, канапа, марс, трава]

[блюдо, повар, комната, вода, квартира, диван, марс, трава]

	↕ skipgram w5	↕ skipgram w10	↕ cbow w5	↕ pretrained
страва	+	+	- духоўка	- пліта
кухар	+	+	- духоўка	+
пакой	+	+	- духоўка	+
вада	+	+	- духоўка	+
кватэра	+	+	- духоўка	+
канапа	+	+	- духоўка	- пліта
марс	- пліта	- пліта	- духоўка	+
трава	+	+	- духоўка	+
Correct predictions	7/8	7/8	0/8	6/8

Оценка качества моделей

Модель	Результат
skip-gram с окном размера 5	75 %
skip-gram с окном размера 10	81,25 %
CBOW с окном размера 5	48,44 %
предобученная с сайта FastText	78,13 %

Поиск семантически близких слов

Существительное: маці мать

Существительное/прилагательное: вучоны учёный

Прилагательное: прыгожы красивый

Числительное: адзінаццаць одиннадцать

Местоимение: ён он

Наречие: хутка быстро, скоро

Поиск семантически близких слов

Слово: маці **мать**

skip-gram с окном размера 5		
слово	перевод	сходство
бацька	отец	0.877
жонка	жена	0.856
нявестка	невеста	0.835
матка	мать	0.824
унучка	внучка	0.811
дачка	дочь	0.810
Светка	Светка	0.810
мама	мама	0.806
брацік	братик	0.802
сын	сын	0.801

CBOW с окном размера 5		
бацька	отец	0.886
жонка	жена	0.867
сын	сын	0.808
матка	мать	0.798
дзіця	ребёнок	0.790
дачка	дочь	0.785
сястра	сестра	0.756
дзед	дед	0.747
малы	малый, небольшой	0.742
муж	муж	0.735

skip-gram с окном размера 10		
слово	перевод	сходство
бацька	отец	0.854
матка	мать	0.825
унучка	внучка	0.814
нявестка	невестка	0.811
дачка	дочь	0.786
дачушка	дочурка	0.785
брацік	братік	0.783
жонка	жена	0.779
цётка	тётка	0.773
сын	сын	0.771

предобученная с сайта FastText		
маці-немкі	матери-немки	0.734
маці-і-мачахі	мать-и-мачехи	0.731
маці.-	мать.-	0.727
Шашандухт		0.690
Сандухт		0.664
бацька-маці	отец-мать	0.644
Мюмлы-маці		0.639
бацька	отец	0.636
Багхмаці		0.632
Гурандухт		0.631

Поиск семантически близких слов

Слово: прыгожы красивый

skip-gram с окном размера 5		
слово	перевод	сходство
інтэлігентны	интеллигентный	0.754
прывабны	соблазнительный	0.749
харошы	красивый	0.746
убранне	убор, наряд	0.741
прычоска	причёска	0.739
сціплы	скромный	0.737
светлавалосы	светловолосый	0.735
гожы	красивый	0.732
сімпатычны	симпатичный	0.730
непрыгожы	некрасивый	0.726

CBOW с окном размера 5		
сціплы	скромный	0.747
дамавітаваць	хозяйствовать	0.736
вясёлы	весёлый	0.736
надзіва	удивительно	0.728
суровы	суровый	0.726
светлы	светлый	0.726
гожы	красивый	0.720
маладжавы	моложавый	0.715
далікатны	деликатный	0.714
хударлявы	худощавый	0.712

skip-gram с окном размера 10		
слово	перевод	сходство
убранне	убор, наряд	0.754
прычоска	причёска	0.752
гожы	красивый	0.750
сціплы	скромный	0.749
прыгажуня	красавица	0.745
сінявокі	синеглазый	0.731
сімпатычны	симпатичный	0.730
ганарысты	высокомерный	0.729
усмешлівы	улыбчивый	0.727
маладжавы	моложавый	0.726

предобученная с сайта FastText		
прыгожыю	некрасивую	0.763
непрыгожы	некрасивый	0.756
Непрыгожы	Некрасивый	0.752
прыгожымі	красивыми	0.734
прыгожым.	красивым.	0.732
прыгож	красив	0.692
прыгож-	красив-	0.686
прыгожу	красиву	0.660
прыгожа.	красиво.	0.626
Прыгожы	Красивый	0.618

Поиск семантически близких слов

Слово: адзінаццаць **одиннадцать**

skip-gram с окном размера 5		
слово	перевод	сходство
шаснаццаць	шестнадцать	0.928
васемнаццаць	восемнадцать	0.928
чатырнаццаць	четырнадцать	0.927
дзевяць	девять	0.926
семнаццаць	семнадцать	0.925
чатырыста	четыреста	0.919
трынаццаць	тринадцать	0.915
адзінаццаты	одиннадцатый	0.913
сорак	сорок	0.912
дзевяноста	девятьноста	0.912

CBOW с окном размера 5		
дзевяць	девять	0.957
сорак	сорок	0.953
восем	восемь	0.938
семнаццаць	семнадцать	0.930
васемнаццаць	восемнадцать	0.925
пятнаццаць	пятнадцать	0.922
шаснаццаць	шестнадцать	0.921
дванаццаць	двенадцать	0.915
паўтара	полтора	0.914
трыццаць	тридцать	0.913

skip-gram с окном размера 10		
слово	перевод	сходство
чатырнаццаць	четырнадцать	0.891
семнаццаць	семнадцать	0.889
гок	излишек, лишнее	0.883
дзевяць	девять	0.882
праслужыць	прослужить	0.876
восьмы	восьмой	0.875
васемнаццаць	восемнадцать	0.873
шосты	шестой	0.873
шаснаццаць	шестнадцать	0.870
трынаццаць	тринадцать	0.869

предобученная с сайта FastText		
адзінаццацю	одиннадцатью	0.701
наццаць	надцать	0.699
Адзінаццаць	Одиннадцать	0.688
двенаццаць	двенадцать	0.664
мнаццаць	мнадцать	0.657
Шаснаццаць	Шестнадцать	0.641
дзвенаццаць	двенадцать	0.629
пяць	пять	0.624
чатырнаццаць	четырнадцать	0.622
семнаццаць	семнадцать	0.617

Поиск семантически близких слов

Слово: хутка быстро, скоро

skip-gram с окном размера 5		
слово	перевод	сходство
неўзабаве	вскоре, в скором времени	0.711
шпарка	быстро, скоро	0.709
найхутчэй	как можно скорее	0.706
борзда	быстро, проворно	0.705
імгненна	мгновенно	0.705
шпарчэй	быстрее	0.688
спакваля	постепенно, потихоньку	0.684
удала	удачно	0.684
няхутка	небыстро	0.684
дахаты	домой	0.682

skip-gram с окном размера 10		
слово	перевод	сходство
неўзабаве	вскоре, в скором времени	0.714
прагначы	желая, жадный	0.700
найхутчэй	как можно скорее	0.688
удала	удачно	0.687
няхутка	небыстро	0.682
своечасова	своевременно	0.680
карцець	хотеться, не терпиться	0.680
цярпецца	терпиться	0.676
шпарка	быстро, скоро	0.674
ненадоўга	ненадолго	0.673

CBOW с окном размера 5		
неўзабаве	вскоре, в скором времени	0.620
марудна	медленно, медлительно	0.578
неяк	как-то	0.558
нечакана	неожиданно	0.542
непрыкметна	незаметно	0.540
наперад	вперёд	0.539
далей	дальше, далее	0.533
памалу	помалу, понемногу	0.531
шпарка	быстро, скоро	0.531
нарэшце	наконец, в конце концов	0.530

предобученная с сайта FastText		
хутка-хутка	быстро-быстро	0.762
няхутка	небыстро	0.693
Няхутка	Небыстро	0.672
ціхутка	тихонько	0.607
добрахвотна	добровольно	0.592
вельмі	очень	0.587
паволі	медленно, потихоньку	0.585
Павольна	Медленно	0.575
хутказ	быстро	0.573
паступова	постепенно	0.566

Арифметические операции с векторами

+ жанчына женщина

+ бацька отец

- мужчына мужчина

skip-gram с окном размера 5		
слово	перевод	сходство
маці	мать	0.819
сын	сын	0.771
муж	муж	0.760
нявестка	невестка	0.742
дачка	дочь	0.742

skip-gram с окном размера 10		
слово	перевод	сходство
маці	мать	0.809
жонка	жена	0.765
сын	сын	0.757
Саша	Саша	0.757
нявестка	невестка	0.746

CBOW с окном размера 5		
маці	мать	0.850
жонка	жена	0.808
сын	сын	0.805
дачка	дочь	0.742
муж	муж	0.736

предобученная с сайта FastText		
маці	мать	0.600
бацька-маці	отец-мать	0.585
-бацька	-отец	0.583
бацька.-	отец.-	0.580
бацька-эстонец	отец-эстонец	0.578

Арифметические операции с векторами

+ жанчына **женщина**

+ хлопец **парень**

- мужчына **мужчина**

skip-gram с окном размера 5		
слово	перевод	сходство
дзяўчына	девушка	0.839
кабет	замужняя	0.721
	женщина	
хлопчык	мальчик	0.716
Хрысціюк		0.711
салдатка	жена солдата	0.707

skip-gram с окном размера 10		
слово	перевод	сходство
дзяўчына	девушка	0.768
Валянціна	Валентина	0.727
Саша	Саша	0.725
Аня	Аня	0.714
яна	она	0.711

CBOW с окном размера 5		
дзяўчына	девушка	0.816
сябар	друг	0.620
чалавек	человек	0.610
хлопчык	мальчик	0.600
баец	боец	0.598

предобученная с сайта FastText		
хлопец.-	парень.-	0.610
хлопецъ	пареньъ	0.589
дзяўчына	девушка	0.566
хлопе		0.516
хлопае		0.493

Арифметические операции с векторами

- + жанчына женщина
- + прадавец продавец
- мужчына мужчина

skip-gram с окном размера 5		
слово	перевод	сходство
нежаданне	нежелание	0.802
інтымны	интимный	0.801
здатнасць	способность	0.800
няўважлівы	невнимательный	0.798
слухны	дельный, резонный	0.798

skip-gram с окном размера 10		
слово	перевод	сходство
далікатнасць	деликатность	0.805
уздзейнічаць	воздействовать	0.788
бібліятэкарка	библиотекарша	0.786
павучальны	поучительный	0.783
падрыхтоўваць	подготавливать	0.782

CBOW с окном размера 5		
скарга	жалоба	0.836
латыш	латыш	0.825
пырэчанне	возражение	0.823
рэпліка	реплика	0.823
Грамыка		0.823

предобученная с сайта FastText		
прадавачка	продащица	0.563
прадаўшчыца	продащица	0.540
Прадавец	Продавец	0.533
прадава		0.525
прадажная	продажная	0.511

Выводы: модели

- Для создания качественных моделей с использованием алгоритма CBOW текущего размера корпуса текстов недостаточно
- Увеличение размера контекстного окна ухудшает результаты поиска семантически близких слов: увеличивается число близких векторов, не имеющих явной связи с исходным словом
- Наилучший результат продемонстрировала модель, обученная с использованием алгоритма skip-gram с контекстным окном размера 5

Выводы: предобученная модель

- Модель с сайта FastText хорошо решает задачи поиска лишнего слова из списка, а также задачи с применением арифметических операций для нескольких векторов
- Из-за отсутствия лемматизации она показывает плохие результаты при поиске семантически близких слов

Выводы: другое

- Результативность поиска семантически близких слов может сильно отличаться в зависимости от части речи
- Имеющегося объёма обучающих текстов достаточно для поиска высокочастотных слов, но недостаточно для поиска более редких слов
- Важно учитывать то, что автоматическая лемматизация слов может работать неидеально